

Sibanki — Estratégia 3: Fine-Tuning de LLM Própria



Roteiro para ter a LLM do Sibanki

Documento estratégico interno — Versão 1.0 — Março 2026

1. O que é Fine-Tuning e por que faz sentido para o Sibanki

Fine-tuning é o processo de **treinar um modelo de linguagem pré-existente** com dados específicos do seu domínio. Em vez de criar uma LLM do zero — o que custaria dezenas de milhões de dólares — você pega um modelo já treinado com conhecimento geral e o **especializa** no seu contexto.

Para o Sibanki, isso significa um modelo que:

- Entende "gastei 45 conto no mercado" e já categoriza como *Alimentação*, valor R\$ 45,00
- Sabe que "Selic", "CDI", "PGBL" e "Tesouro Selic" são termos do mercado financeiro brasileiro
- Responde como o personagem **Siba** (tom amigável, direto, com emojis)
- Não "alucina" categorias inexistentes — só usa as 16 categorias do Sibanki
- Não precisa de um prompt gigante explicando o contexto a cada chamada

Resultado: respostas mais rápidas, mais precisas e com custo ~10x menor que chamar Gemini ou GPT para cada interação.

2. Contexto atual vs. futuro

	Hoje (API externa)	Futuro (modelo fine-tunado)
Custo por request	~R\$ 0,002–0,01	~R\$ 0,0001–0,0003
Latência média	2–5 segundos	0,3–1 segundo
Limite de uso	Rate limit do provedor	Ilimitado
Dependência externa	Alta (Google, OpenAI)	Zero
Dados do usuário	Saem para servidor externo	Ficam no Sibanki
Contexto financeiro BR	Prompt longo toda vez	Embutido no modelo
Personagem Siba	Instrução repetida	Comportamento nativo

3. Pré-requisitos — Volume de dados necessário

Fine-tuning supervisionado (SFT) requer exemplos de entrada→saída:

Tarefa	Exemplos mínimos	Exemplos ideais
Extração de lançamento (WhatsApp, voz)	500	3.000+
Categorização automática	300	2.000+
Geração de insight financeiro	200	1.000+
Resposta como Siba (tom e estilo)	300	1.500+
Análise de orçamento/meta	200	800+
Total	~1.500	~8.000+

Importante: 1.500 exemplos de alta qualidade já produzem resultados notáveis com modelos de 7B–8B parâmetros.

3.1 Fontes de dados para o dataset

Dados sintéticos gerados com GPT-4o/Gemini Pro (fase inicial):

- Gerar centenas de variações de frases financeiras em PT-BR
- Simular diferentes perfis de usuário (autônomo, CLT, empresário)
- Incluir erros de digitação, gírias, abreviações regionais

Dados reais anonimizados (fase de crescimento, com consentimento):

- Usuários Pro/Família que ativarem "contribuir para IA"
- Remover PII (nome, CPF, valores exatos) antes de usar no treino
- Cada usuário que contribui melhora o modelo para todos

Dados curados manualmente:

- Time Sibanki cria 200–300 exemplos de casos-limite
- Frases ambíguas, categorias difíceis, linguagem regional

3.2 Formato do dataset (JSONL padrão)

```
{ "messages": [
  { "role": "system", "content": "Você é o Siba, assistente do Sibanki..." },
  { "role": "user", "content": "gastei 89 reais no mercado hoje" },
  { "role": "assistant", "content": "{ \"type\": \"despesa\", \"value\": 89,
    \"desc\": \"Mercado\", \"category\": \"Alimentação\" }" }
]}

{ "messages": [
  { "role": "system", "content": "Você é o Siba, assistente do Sibanki..." },
  { "role": "user", "content": "recebi meu salário de 4500" },
  { "role": "assistant", "content": "{ \"type\": \"receita\", \"value\": 4500,
    \"desc\": \"Salário\", \"category\": \"Salário\" }" }
]}
```

4. Escolha do modelo base

Modelo	Parâmetros	VRAM necessária	Custo treino (est.)	Qualidade PT-BR
Qwen 2.5 7B 	7B	14–20 GB	~R\$ 120–250	Muito boa
Llama 3.1 8B	8B	16–24 GB	~R\$ 150–300	Boa
Mistral 7B v0.3	7B	14–20 GB	~R\$ 100–200	Boa
Phi-3.5 Mini	3.8B	8–12 GB	~R\$ 60–120	Razoável

Recomendação: Qwen 2.5 7B Melhor desempenho em português entre os modelos open-source, excelente em tarefas estruturadas (extração de JSON), licença Apache 2.0 (uso comercial livre).

5. Infraestrutura de treino

Opção A — Cloud sob demanda (início, recomendado)

RunPod ou Vast.ai com GPU A100 40GB:

- Custo: ~US\$ 1,80–2,50/hora
- Tempo de treino (8B + 3.000 exemplos): 4–8 horas
- **Custo por rodada de treino: US\$ 10–20 (~R\$ 60–110)**
- Pague só quando treina, sem custo fixo mensal

Opção B — Servidor próprio (escala)

A partir de ~500 usuários ativos usando IA diariamente:

- GPU NVIDIA RTX 4090 (24GB VRAM): R\$ 8.000–12.000
- Servidor base 64GB RAM: R\$ 6.000–8.000
- **Total hardware:** ~R\$ 15.000–20.000 (investimento único)
- **Custo mensal:** apenas energia elétrica ~R\$ 200–300
- **Payback:** com 500 usuários = economia de R\$ 1.500–3.000/mês vs. API → payback em 6–12 meses

Ferramentas de treino recomendadas

Unsloth – 2x mais rápido, 70% menos VRAM (ideal para início)
LlamaFactory – interface completa com config YAML
Axolotl – mais flexível, ótimo para datasets customizados

6. Pipeline completo de fine-tuning

FASE 1 – COLETA DE DADOS

Geração sintética (GPT-4o): ~2.000 exemplos de frases PT-BR
Curadoria manual: ~300 casos-limite e exceções
Dados reais anonimizados (com consentimento): acumulando

FASE 2 – PREPARAÇÃO

Converter para formato JSONL (chat format)
Validar JSON em todas as respostas de treino
Split: 80% treino / 10% validação / 10% teste
Tokenizar com tokenizer do modelo base escolhido

FASE 3 – TREINO (QLoRA – Parameter-Efficient Fine-Tuning)

Base: Qwen 2.5 7B Instruct
Método: LoRA (rank 16, alpha 32)
Epochs: 3-5
Batch size: 4 (gradient accumulation steps: 4)
Learning rate: 2e-4 com warmup schedule
Hardware: 1x A100 40GB / duração: ~4-6h

FASE 4 – AVALIAÇÃO

Acurácia extração JSON: meta > 95%
Acurácia categoria: meta > 92%
Qualidade de resposta (avaliação humana): meta > 80%
Comparativo com Gemini Flash no mesmo conjunto de teste

FASE 5 – DEPLOY

Quantizar para GGUF Q4_K_M (4x menor, mesma qualidade)
Subir para servidor via Ollama ou vLLM
Endpoint compatível com OpenAI: POST /v1/chat/completions
Adicionar como provider "sibanki" no llmService.js

7. Integração com o llmService.js existente

O `llmService.js` já foi implementado com arquitetura multi-provider. Adicionar o modelo próprio requer apenas incluir mais um provedor:

```
// Adicionar ao llmService.js quando o modelo estiver pronto
async function _callSibankiLLM(prompt, maxTokens) {
  const URL = process.env.SIBANKI_LLM_URL || "";
  if (!URL) return null;
  const res = await fetch(`${URL}/v1/chat/completions`, {
    method: "POST",
    headers: { "Content-Type": "application/json" },
    body: JSON.stringify({
      model: "sibanki-qwen-7b",
      messages: [{ role: "user", content: prompt }],
      max_tokens: maxTokens, temperature: 0.2
    })
  })
```

```
});  
const json = await res.json();  
return json.choices?.[0]?.message?.content || null;  
}  
  
// Nova ordem: modelo próprio primeiro, APIs como fallback  
const fastOrder = [_callSibankiLLM, _callGemini, _callOpenAI, _callClaude];
```

Quando o modelo próprio está no ar, ele vira o primeiro da fila. Os outros continuam como fallback. Zero risco de downtime na transição.

8. Roadmap de implementação

Fase 0 — Agora (IMPLEMENTADO)

Multi-provider com fallback automático via llmService.js
Gemini → OpenAI → Claude Haiku, com cache inteligente
Custo estimado: R\$ 5–25/mês para 500 usuários

Fase 1 — 3 a 6 meses (200+ usuários ativos)

Ativar logging de pares entrada→saída com consentimento do usuário
Gerar 2.000 exemplos sintéticos com GPT-4o (~R\$ 200)
Criar pipeline de validação automática do dataset
Custo desta fase: R\$ 300–600

Fase 2 — 6 a 12 meses (500+ usuários ativos)

Primeiro fine-tuning do Qwen 2.5 7B no RunPod (~R\$ 100 por rodada)
Deploy via Ollama em VPS com GPU (R\$ 200–400/mês)
Teste A/B: 10% dos usuários no modelo próprio vs. Gemini
Meta: modelo próprio com qualidade igual ou superior ao Gemini Flash

Fase 3 — 12 a 18 meses (1.000+ usuários)

Modelo próprio como provedor principal (APIs como fallback)
Retreino mensal com novos dados — melhoria contínua
Hardware dedicado se VPS superar R\$ 800/mês
Explorar modelos menores (3B) para tarefas simples (latência < 200ms)

9. Privacidade e LGPD — Diferencial competitivo

Com API externa (hoje): dados financeiros do usuário saem do Brasil e são processados em servidores do Google, OpenAI ou Anthropic. Há risco regulatório.

Com modelo próprio: dados ficam nos servidores do Sibanki, no Brasil. Conformidade total com a LGPD. Pode ser usado como diferencial competitivo nos materiais de marketing:

"Sua IA financeira roda aqui. Seus dados não saem daqui."

10. Estimativa de ROI

Métrica	Hoje (500 usuários, API)	Fase 3 (1.000 usuários, modelo próprio)
Custo IA/mês	R\$ 25–50	R\$ 200–300 (VPS)
Custo por usuário/mês	R\$ 0,05–0,10	R\$ 0,20–0,30
Latência média	2–5s	0,3–1s

Rate limit	Sim (risco real)	Não
Dados no Brasil	Não	Sim (LGPD )
Personalização	Prompt (frágil)	Fine-tuned (robusta)

Em 2.000 usuários, o custo por usuário com modelo próprio é 5x menor que API externa.

 Próximos passos imediatos

1. Configurar OPENAI_KEY e CLAUDE_KEY no Firebase para ativar o fallback agora
2. Ativar logging de pares entrada/saída no llmService.js (flag de consentimento)
3. Criar script de geração sintética de dataset com GPT-4o
4. Definir KPI de qualidade: meta de 95% acurácia na extração de lançamentos
5. Revisitar este roadmap quando atingir 200 usuários ativos pagantes

Documento interno Sibanki — Atualizar a cada milestone de crescimento de usuários.